

TP : La station météo

Le jeu de données

Dans ce TP nous allons commencer à manipuler des données d'observation du réseau de stations de MétéoFrance.

Le jeu de données utilisé pour ce TP est une sous-partie du jeu de données Meteonet <https://meteofrance.github.io/meteonet/french/accueil/>

Il s'agit d'un an de données observées (au pas de temps horaire) sur certaines stations du Nord Ouest de la France.

Vous trouverez ce jeu de données sous :

```
/home/newton/horsenm/destouchesm/COURS_CS/data/station_2018.csv
```

Inutile de le copier chez vous, vous pouvez directement l'utiliser dans vos scripts python.

But du TP

Dans ce TP on va voir comment extraire de l'information du fichier csv via l'implémentation de différentes fonctions.

Nous allons notamment voir :

- Comment lire un fichier csv (via Pandas)
- Comment manipuler des dates

Pour ce TP il vous faudra installer pandas et matplotlib.

1. Activer l'environnement virtuel créé lors du dernier TP.
2. Faire ensuite

```
pip install pandas matplotlib
```

Lecture et ouverture du fichier

Pour lire et manipuler ce fichier, nous allons utiliser la librairie Pandas.

```
import pandas as pd
# Lecture du fichier
file_path = "/home/newton/horsenm/destouchesm/COURS_CS/data/station_2018.csv"
df = pd.read_csv(file_path, parse_dates=[4])
# Affichage des premières lignes du fichier
print(df.head())
```

L'identifiant de chaque station est donné par la colonne `number_sta`.

Le fichier csv contient 12 colonnes :

```
['number_sta', 'lat', 'lon', 'height_sta', 'date', 'dd', 'ff', 'precip', 'hu', 'td',  
't', 'psl']
```

Accéder aux identifiants d'une station

Le dataframe marche dans un certain sens comme un dictionnaire.
Pour accéder à une colonne, on va utiliser une des 12 clés disponibles

```
# Affichage des stations
print(df["number_sta"])
# Affichage de tous les identifiants
print(df["number_sta"].unique())
```

Explications :

- `df["number_sta"]` permet d'accéder à tous les éléments de la colonne `number_sta`
- `.unique()` permet d'enlever toutes les valeurs en doublons.

Exercice

Combien existe-t-il d'identifiants de stations dans ce fichier ?

La réponse peut être donnée en utilisant `len` (qui retourne le nombre d'éléments)

```
len(df["number_sta"].unique())
```

ou un attribut propre aux tableaux numpy permettant d'accéder à sa taille

```
df["number_sta"].unique().size
```

ou par `shape` permettant de donner les dimensions d'un tableau numpy

```
df["number_sta"].unique().shape
```

Question : Comparer le résultat retourné par `df.shape` et `df.size` .

Lire et sélectionner les éléments d'une station

On va commencer par créer une fonctionnalité permettant de retourner l'ensemble des éléments d'une station. Pour cela, on va filtrer la `Dataframe`.

```
def read_station_data(id_number):  
    df = pd.read_csv(file_path, parse_dates=[4])  
    # Check that the id exists  
    if id_number not in df["number_sta"].unique():  
        print(f"La station demandée {id_number} n'existe pas.")  
        print(f"Les possibilités sont {df["number_sta"].unique()}")  
        raise ValueError(f"Station {id_number} does not exist!")  
    # Filter by station number  
    return df[df["number_sta"] == id_number]
```

- `df["number_sta"] == id_number` permet de savoir si l'élément est associé à la station `id_number`. Cela crée un tableau de booléens.
- `df[df["number_sta"] == id_number]` retourne uniquement les lignes du fichier csv associées à la station `id_number`.

Amélioration du code précédent

Que se passe-t-il si on veut les données de plusieurs stations ?
Comment y remédier ?

Que se passe-t-il si on veut les données de plusieurs stations ?

Le fichier contenant les données est lu plusieurs fois. Pour des fichiers volumineux, cela peut impacter grandement les performances de votre code.

Comment y remédier ?

On peut lire une fois le fichier en dehors de la fonction, puis le passer en argument.

```
def read_station_data(df: pd.DataFrame, id_number: int) -> pd.DataFrame:
    """
    df (pd.DataFrame) : Pandas dataframe containing data
    id_number (int): Station number
    """
    # Check that the id exists
    if id_number not in df["number_sta"].unique():
        print(f"La station demandée {id_number} n'existe pas.")
        print(f"Les possibilités sont {df['number_sta'].unique()}")
        raise ValueError(f"Station {id_number} does not exist!")
    # Filter by station number
    return df[df["number_sta"] == id_number]
```

Exercice

Faites une fonction qui affiche les informations propres à la station à savoir :

- latitude
- longitude
- altitude,

Une réponse possible

```
def print_station_info(df: pd.DataFrame, id_number: int) -> None:
    data = read_station_data(df, id_number)
    print(f" Information pour la station {id_number}")
    print(f" Latitude de la station : {data["lat"].unique()}")
    print(f" Longitude de la station : {data["lon"].unique()}")
    print(f" Hauteur de la station : {data["height_sta"].unique()}")
```

Votre station a-t-elle bougé dans l'année ?

Question

Dans le code suivant, que signifie d'après vous l'argument `parse_dates=[4]` ?

```
df = pd.read_csv(file_path, parse_dates=[4])
```

Pour rappel, les colonnes du fichiers sont :

```
['number_sta', 'lat', 'lon', 'height_sta', 'date', 'dd', 'ff', 'precip', 'hu', 'td',  
't', 'psl']
```

Les dates (Aparté)

Les dates sont des données très particulière. En python, il existe plusieurs classes permettant de les gérer. La plus classique est la classe `datetime`.

```
import datetime as dt
start_class = dt.datetime(2026, 10, 6, 13, 55)
end_class = start_class + dt.timedelta(minutes=115)
print(f"Le cours débute à {start_class} et termine à {end_class}")
```

Explications :

- `dt.datetime(2026, 10, 6, 13, 55)` : On passe l'année, le mois, le jour, l'heure, les minutes ...
- `dt.timedelta` : Permet d'ajouter ou de retrancher des jours/heures/minutes à une date.

Les dates (Aparté)

Il est aussi possible d'accéder directement à différents attributs de la date (par exemple l'heure, le jour de la semaine, ...).

Pour cela il suffit de faire :

```
start_class.hour
```

Attention : La gestion des dates est la plupart du temps une étape complexe. Bien que `datetime` nous simplifie la vie, cela peut rester complexe.

Filtrer une période

Pour filtrer une période de notre dataframe, nous allons utiliser les propriétés de la date.

```
# Lecture (dans df déjà chargé) des données de la station
df_station = read_station_data(df, id_number=22219003)
# Définition du début et fin de période pour le filtrage
start_period = dt.datetime(2018, 10, 1)
end_period = dt.datetime(2018, 10, 15)
# Recherche des dates satisfaisant les deux conditions
selected = (df_station.date > start_period) * (df_station.date < end_period)
# Sélection de la bonne période
df_period = df_station[selected]
# Affichage de la dataframe pour les dates sélectionnées
print(df_period)
```

Exercice

Créer une fonction `select_period` permettant de sélectionner une sous-période d'un dataframe. Ajouter un argument optionnel permettant de sélectionner une heure précise de la journée au sein de cette période.

Réponse

```
def select_period(df, start_period, end_period, hour=None):  
    # On reprend l'exemple de la slide précédente  
    cdt = (df.date > start_period) * (df.date < end_period)  
    # Mise à jour de la condition pour rajouter la sélection de l'heure  
    if hour is not None: # Attention `if hour:` ne fonctionne pas avec 0.  
        cdt = cdt * (df.date.dt.hour == hour)  
    df_period = df[cdt]  
  
    return df_period
```

Exercice

Pour cet exercice, nous allons étudier la période allant du 1er Octobre au 15 Octobre pour la station 22219003.

A quelle(s) date(s) la température maximum a-t-elle été atteinte sur la période ?

Cela correspond-il au moment de la journée pour lequel en moyenne la température est maximale sur la période (maximum du cycle journalier moyen) ?

NB : La température est stockée dans la colonne de la dataframe dénotée `t`.

Bonus : Refaire la même chose en arrondissant la moyenne des températures à la valeur entière la plus proche. Trouvez-vous la/les même heure ?

Si non, avez vous une idée du problème ?

Une solution

```
df_station = read_station_data(df, id_number=22219003)
start_period = dt.datetime(2018, 10, 1)
end_period = dt.datetime(2018, 10, 15)
df_period = select_period(df_station, start_period, end_period)
max_temperature = df_period["t"].max()

# Liste des éléments ayant atteint cette température maximum.
elt = df_period[df_period["t"] == max_temperature]

print(f"La température maximale sur la période a été de {max_temperature}.")
print(f"Elle a été atteinte pour les dates suivantes : {elt["date"].dt.strftime("%Y%m%d-%H").values}")
# On va maintenant trouver la moyenne horaire maximale
# Dictionnaire qui va contenir le maximum pour chaque heure
mean_hour = {
    "hour": [],
    "value": []
}
# On calcule la moyenne pour chaque heure
for i in range(0, 24):
    df_period = select_period(df_station, start_period, end_period, hour=i)
    print(len(df_period))
    mean_hour["hour"].append(i)
    mean_hour["value"].append(df_period["t"].mean())
# On recherche le maximum
mean_max = np.max(mean_hour["value"])
# On regarde quand ce maximum a été atteint
index_max = mean_hour["value"].index(mean_max)
# On regarde ensuite l'heure de ce maximum
print(f"L'heure pour laquelle ce maximum a été atteint est {mean_hour['hour'][index_max]} H")
```

Bonus


Le problème de la solution précédente vient de l'utilisation d' `index` .

Cette méthode renvoie la première occurrence de la valeur cherchée de la liste.

Il faudrait faire une boucle explicite recherchant la valeur pour avoir toutes les heures correspondant.

Exercices

- Ecrire une fonction prenant en entrée un dataframe, la variable d'intérêt (`t`, `hu`, `td`, ...) et retournant l'heure du premier maximum et du premier minimum sur la période.
- Ecrire une fonction prenant en entrée un dataframe, la variable d'intérêt (`t`, `hu`, `td`, ...), la fonction d'agrégation (`mean`, `max`, `min`) et retournant la valeur agrégée par heure de la journée
- Ecrire une fonction permettant de visualiser la moyenne horaire sur la période



Une solution Extrema

```
def extrema(df: pd.DataFrame, variable: str):  
    """  
    Regarde pour une variable donnée la première heure pour  
    laquelle le maximum/minimum a été atteint.  
    """  
  
    maxi = df[variable].max()  
    mini = df[variable].min()  
    # Filtre pour ne garder que les éléments correspondants au maximum  
    max_date = df[df[variable] == maxi]  
    # au minimum  
    min_date = df[df[variable] == mini]  
    heure_max = max_date["date"].dt.strftime("%H").values[0]  
    heure_min = min_date["date"].dt.strftime("%H").values[0]  
    return (heure_max, heure_min)
```

Une solution pour l'agrégation

```
def aggregation(df:pd.DataFrame, variable:str, method:str):  
    # Création d'une liste pour mettre la donnée agrégée  
    result = []  
    for hour in range(0, 24):  
        cdt = df.date.dt.hour == hour  
        df_selected = df[cdt]  
        if method == "mean":  
            result.append(df_selected[variable].mean())  
        elif method == "min":  
            result.append(df_selected[variable].min())  
        elif method == "max":  
            result.append(df_selected[variable].max())  
        else:  
            raise ValueError("Aggregation method unknown")  
    return result
```

Autre solution pour l'agrégation

```
def aggregated_bis(df, variable, method):  
    result = []  
    for hour in range(0, 24):  
        cdt = df.date.dt.hour == hour  
        df_selected = df[cdt]  
        if method in ["mean", "max", "min"]:  
            # On utilise getattr afin de requêter l'attribut correspondant à notre  
            # méthode et on l'applique  
            result.append(df_selected[variable].__getattr__(method)())  
        else:  
            raise ValueError("Aggregation method not known")
```

Cette solution est plus complexe à lire. Cependant, elle est plus facilement extensible à d'autres fonctionnalités que possède notre objet. On peut à l'aide de la fonction `dir` avoir une idée des principales fonctionnalités de notre objet, par exemple:

```
dir(df["t"])
```

Résumé

Nous disposons maintenant :

- d'une fonction permettant d'extraire les données correspondant à une station d'un dataframe
- d'une fonction permettant de filtrer une période particulière du jeu de données
- d'une fonction permettant d'extraire l'heure du maximum et du minimum pour une variable
- d'une fonction permettant d'agréger les données d'une période par heure de la journée
- d'une fonction de visualisation du cycle journalier

Nous verrons lors du prochain cours comment nous pouvons nous en servir pour créer un "objet" station.